


Licenciatura en Actuaría
Series de Tiempo
Semestre enero-mayo 2026
ADA 2
Grupo 14. Mauricio Becerril y Axel Solís

En el siguiente trabajo se realiza un análisis estadístico sobre la serie de tiempo el Índice Nacional de Precios al Consumidor INPC de México comprendido del periodo de enero 2022 hasta marzo del 2026, registrado de manera mensual. Esta serie se llamará $\{Y_t\}$

Identificación del Modelo ARIMA

El primer paso será analizar si esta serie es estacionaria, es decir que se puede apreciar que su media y varianza son constantes, de lo contrario se realizarán las transformaciones necesarias a $\{Y_t\}$ hasta que sea estacionaria.


Figura 1



Por el contexto del problema se sabe que el INPC en México no es constante, ya que año con año este índice sube por su naturaleza, debido a factores socioeconómicos como la inflación nacional, lo que hace que este índice aumente con el paso del tiempo, es decir que no tenga media constante.

En la gráfica (Figura 1) del INPC en México (2022, enero – 2026, marzo) se observa una tendencia creciente, oscilando en una línea diagonal y no en una línea horizontal. Este comportamiento sugiere que no tiene una media constante el INPC, lo que indica que la media cambia a lo largo del tiempo. Por ello, la serie original no es estacionaria (no WSS).

FIGURA 2



Para corregir la no estacionariedad en media, se aplica una diferenciación de primer orden, observándose en la figura 2, que la serie resultante oscila alrededor de 0.5, eliminando la tendencia y manteniendo una media constante. Esto indica que la media se ha estabilizado.

Con base en esa observación gráfica, podemos concluir que la diferenciación de primer orden consigue estabilizar la media.

En cuanto a la varianza, observamos numerosos picos aislados permaneciendo fuera de las bandas donde los valores oscilan. Esto sugiere que la varianza no es constante a lo largo de los años.

```
> #se pone la serie original NO la diferencia
> lambda1 <- BoxCox.lambda(inpc.ts, method = c("loglik"), lower = -1, upper = 5)
> lambda1
[1] 3.85
```

El análisis mediante Box–Cox arroja un valor de $\lambda = 3.85$, lo que indica que sí es conveniente aplicar esta transformación.




Figura 3

Al comparar la serie diferenciada con la serie transformada y diferenciada, se observa en la figura 3, que esta última presenta menor amplitud en los picos extremos por ejemplo en los años 2022, 2023, 2024 y 2025, logrando una dispersión más homogénea y, por tanto, una mejor estabilización de la varianza.

En consecuencia, para lograr una serie estacionaria, se aplican ambas transformaciones: primero Box–Cox para estabilizar la varianza y luego diferenciación para estabilizar la media. Cumpliendo las condiciones para que la serie sea débilmente estacionaria (WSS)


En consecuencia, la serie a modelar se define como:

$$Z_t = Y_t^{(\lambda)} - Y_{t-1}^{(\lambda)} \text{ con } \lambda = 3.85$$

La cual resulta de aplicar una transformación Box–Cox seguida de una diferenciación de primer orden, logrando así una serie estacionaria adecuada para su modelación.

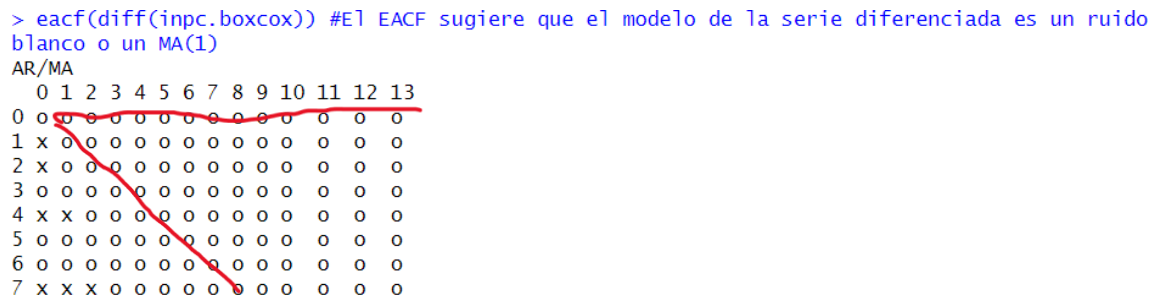
Procedemos al ajuste del modelo adecuado para nuestra serie transformada $Z_t = Y_t^{(\lambda)} - Y_{t-1}^{(\lambda)}$, para ello procederemos mediante en análisis de la Función de Autocorrelación (ACF) y Autocorrelación Parcial (PACF).

Figura 4



Al analizar las funciones de autocorrelación (ACF) y autocorrelación parcial (PACF), se observa en la figura 4, que en ambos todos los rezagos caen hacia cero, es decir, que el modelo no sugiere comportarse como un modelo autorregresivo $AR(p)$ ni como un modelo de medias móviles $MA(q)$, es decir la serie propuesta Z_t se comporta como un ruido blanco.

Figura 5



Ante la falta de una identificación concluyente mediante ACF y PACF, se recurre al análisis de la función de autocorrelación extendida (EACF) en la figura 5, donde podemos ver la relación de los componentes $AR(p)$ en las filas y los $MA(q)$ en las columnas del modelo que se sugiere usar, los parámetros p, q se escogen de acuerdo con patrones triangular a partir del vértice donde inician los rezagos del modelo propuesto anteriormente.

A partir de esta, se identifican dos posibles modelos candidatos: $ARIMA(0,1,0)$, y $ARIMA(0,1,1)$, debido a la presencia de un patrón triangular que sugiere valores iniciales en $p=0$ y $q=0$, y $p=0$ y $q=1$ respectivamente.

Evaluación y estimación de los parámetros para el modelo para $ARIMA(0,1,0)$:

El modelo es un ARIMA(0,1,0) con valores $p=0$, $d=1$ y $q=0$ y como $Z_t = Y_t^{(\lambda)} - Y_{t-1}^{(\lambda)}$, se usó la función Arima con una diferenciación $d=1$. Incluimos el drift en el modelo.

Por lo tanto, la ecuación del modelo estimado es:

$$Z_t = c + \varepsilon_t$$

$$\therefore Y_t^{(\lambda)} - Y_{t-1}^{(\lambda)} = c + \varepsilon_t$$

Calculamos los coeficientes y los reemplazamos en la ecuación:

- Summary(modeloARIMA010)

```
Series: inpc.ts
ARIMA(0,1,0) with drift
Box Cox transformation: lambda= 3.85
```

```
Coefficients:
      drift
      611897.45
s.e.      57620.96
```

```
sigma^2 = 1.694e+11: log likelihood = -716.83
AIC=1437.67 AICc=1437.92 BIC=1441.49
```

```
Training set error measures:
```

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
Training set	-0.002880745	0.3483741	0.2551628	-0.00296395	0.192833	0.04259539	0.2502964

Por lo tanto, la ecuación para el modelo ARIMA(0,1,0) es: $Y_t^{(\lambda)} - Y_{t-1}^{(\lambda)} = 611,897.45 + \varepsilon_t$

Evaluación y estimación de los parámetros para el modelo para ARIMA(0,1,1):

El modelo es un ARIMA(0,1,1) con valores $p=0$, $d=1$ y $q=1$ y como $Z_t = Y_t^{(\lambda)} - Y_{t-1}^{(\lambda)}$, se usó la función Arima con una diferenciación $d=1$. Incluimos el drift en el modelo.

Por lo tanto, la ecuación del modelo estimado es:

$$Z_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

$$\therefore Y_t^{(\lambda)} - Y_{t-1}^{(\lambda)} = c + \varepsilon_t + \theta_1 \varepsilon_{t-1}$$

Calculamos los coeficientes y los reemplazamos en la ecuación:

- Summary(modeloARIMA011)

```
Series: inpc.ts
ARIMA(0,1,1) with drift
Box Cox transformation: lambda= 3.85
```

Coefficients:

```
      ma1      drift
0.4261  621215.04
s.e.  0.1444   77174.79
```

```
sigma^2 = 1.541e+11: log likelihood = -714.04
AIC=1434.09  AICC=1434.61  BIC=1439.83
```

Training set error measures:

```
      ME      RMSE      MAE      MPE      MAPE      MASE
Training set -0.003186332  0.3260726  0.2376047 -0.003228361  0.1792427  0.03966435
```

Por lo tanto, la ecuación para el modelo ARIMA(0,1,1) es: $\therefore Y_t^{(\lambda)} - Y_{t-1}^{(\lambda)} = 621,215.04 + \varepsilon_t + 0.4261\varepsilon_{t-1}$

Comprobación de estacionariedad e invertibilidad para ARIMA(0,1,0) y ARIMA(0,1,1)

La estacionariedad se verifica analizando las raíces del polinomio autorregresivo, mientras que la invertibilidad se verifica mediante las raíces del polinomio de medias móviles. En ambos casos, las raíces deben estar fuera del círculo unitario.

- **Para ARIMA(0,1,0):** $Y_t^{(\lambda)} - Y_{t-1}^{(\lambda)} = 611,897.45 + \varepsilon_t$ como no cuenta con parte autorregresiva ni medias móviles, ya que es una caminata aleatoria, verifiquemos estacionariedad con la esperanza, varianza y autocovarianza.

$$E(Y_t^{(\lambda)} - Y_{t-1}^{(\lambda)}) = E(611,897.45 + \varepsilon_t) = E(611,897.45) + E(\varepsilon_t)$$

$\Rightarrow 611,897.45 + 0 = 611,897.45$ Ya que ε_t es un ruido blanco, por lo tanto, la serie tiene media constante

$$Var(Y_t^{(\lambda)} - Y_{t-1}^{(\lambda)}) = Var(611,897.45 + \varepsilon_t) = Var(611,897.45) + Var(\varepsilon_t)$$

$\Rightarrow 0 + \sigma^2 = \sigma^2$, por lo tanto, la serie tiene varianza constante.

Definimos previamente a $Z_t = Y_t^{(\lambda)} - Y_{t-1}^{(\lambda)}$, se sabe que:

$$Z_t = 611,897.45 + \varepsilon_t \text{ y } Z_{t-k} = 611,897.45 + \varepsilon_{t-k}$$

$$\text{Calculemos } Cov(Z_t, Z_{t-k}) = Cov(611,897.45 + \varepsilon_t, 611,897.45 + \varepsilon_{t-k})$$

$\Rightarrow Cov(\varepsilon_t, \varepsilon_{t-k})$ por las notas del profesor y como ε_t es un ruido blanco.

$$Cov(\varepsilon_t, \varepsilon_{t-k}) = \begin{matrix} \sigma^2 & \text{para } k=0 \\ 0 & \text{para } k \neq 0 \end{matrix}$$

Por lo que para $k \neq 0 \Rightarrow Cov(Z_t, Z_{t-k}) = 0$

Dado que los errores son ruido blanco e independientes, la covarianza entre distintos rezagos es cero. Por lo tanto, la serie diferenciada no presenta autocorrelación.

Como presenta media y varianza constante, y covarianza cero, la serie diferenciada del modelo ARIMA(0,1,0) presenta estacionariedad.

El modelo tiene parte MA(0), cuyo polinomio de medias móviles no presenta raíces, por lo que se considera invertible. Además, el término de error puede expresarse directamente en función de la serie, lo que confirma la invertibilidad

$$\varepsilon_t = Z_t - 611,897.45$$

- **Para ARIMA(0,1,1):** En este caso no cuenta con parte de modelo autorregresivo pero si con parte de medias móviles de orden 1, para verificar estacionariedad hacemos un análisis similar del modelo anterior.

$$E(Y_t^{(\lambda)} - Y_{t-1}^{(\lambda)}) = E(621,215.04 + \varepsilon_t + 0.4261\varepsilon_{t-1}) = E(621,215.04) + E(\varepsilon_t) + E(0.4261\varepsilon_{t-1}) \Rightarrow 621,215.04 + 0 + 0 = 621,215.04 \text{ Tiene media constante}$$

$$Var(Y_t^{(\lambda)} - Y_{t-1}^{(\lambda)}) = Var(621,215.04 + \varepsilon_t + 0.4261\varepsilon_{t-1}) + Var(621,215.04) + Var(\varepsilon_t) + Var(0.4261\varepsilon_{t-1}) \Rightarrow 0 + \sigma^2 + (0.4261)^2 \cdot \sigma^2 = 1.18156 \cdot \sigma^2 \text{ Tiene varianza constante}$$

Se sabe que $Z_t = 621,215.04 + \varepsilon_t + 0.4261\varepsilon_{t-1}$ y que $Z_{t-k} = 621,215.04 + \varepsilon_{t-k} + 0.4261\varepsilon_{t-k-1}$

$$\Rightarrow Cov(Z_t, Z_{t-k}) = Cov(\varepsilon_t + 0.4261 \cdot \varepsilon_{t-1}, \varepsilon_{t-k} + 0.4261 \cdot \varepsilon_{t-k-1})$$

$$\text{Expandiendo: } \Rightarrow Cov(\varepsilon_t, \varepsilon_{t-k}) + 0.4261 \cdot Cov(\varepsilon_t, \varepsilon_{t-k-1}) + 0.4261 \cdot Cov(\varepsilon_{t-1}, \varepsilon_{t-k}) + (0.4261)^2 \cdot Cov(\varepsilon_{t-1}, \varepsilon_{t-k-1})$$

Por propiedad de Ruido Blanco:

$$Cov(\varepsilon_t, \varepsilon_s) = \begin{cases} \sigma^2 & \text{para } t=s \\ 0 & \text{para } t \neq s \end{cases} \text{ para cualquier } k > 1 \text{ todos los índices son distintos en}$$

$Cov(Z_t, Z_{t-k})$, por lo tanto, presenta covarianza cero y como tiene media y varianza constante la serie ARIMA(0,1,1) presenta estacionariedad.

Analizando la invertibilidad en el polinomio MA(1) de Z_t es $\theta(B) = 1 + 0.4261B$ igualando a cero.

$$1 + 0.4261B = 0 \Rightarrow B = \frac{-1}{0.4261} = -2.347 \text{ aplicando valor absoluto. } |B| = 2.347 > 1$$

Se cumple que la raíz se encuentra fuera del círculo unitario.


Por lo tanto, el modelo es invertible, ya que satisface la condición necesaria de que todas las raíces del polinomio de medias móviles tengan módulo mayor que uno.

- En conclusión las series diferenciadas de los modelos ARIMA(0,1,0) y ARIMA(0,1,1) son estacionarias y son invertibles, procedemos a validar los supuestos.

Validación de los supuestos para ARIMA(0,1,0) y ARIMA(0,1,1)

Graficamos el ACF y el PACF para los residuos de ambos modelos descritos anteriormente, dándonos el siguiente gráfico;

Figura 6



Se ajustan los modelos ARIMA(0,1,0) y ARIMA(0,1,1), se analizan las funciones ACF y PACF de sus residuos observados en la figura 6. En la gráfica se observa que los modelos no contradicen que sean WSS ya que todos sus rezagos en ambos modelos se encuentran dentro de las bandas de confianza, lo que indica ausencia de autocorrelación significativa

Se realiza la prueba de Ljung–Box para el modelo **ARIMA(0,1,0)** con un nivel de significancia $\alpha = 0.05$ y 20 rezagos:

$$H_0: \rho_1 = \rho_2 = \dots = \rho_{20} = 0$$

H_1 : Existe al menos una i tal que $\rho_i \neq 0$

Box-Ljung test

```
data: residuos010
X-squared = 26.413, df = 20, p-value = 0.1526
```

Dado que el $p - \text{valor} = 0.1526 > \alpha = 0.05$ no se rechaza H_0 .

$\therefore$ Por lo que no hay evidencia de autocorrelación en los residuos, confirmando que se comportan como ruido blanco.

Se realiza la prueba de Ljung–Box para el modelo **ARIMA(0,1,1)** con un nivel de significancia $\alpha = 0.05$ y 20 rezagos:

$$H_0: \rho_1 = \rho_2 = \dots = \rho_{20} = 0$$

H_1 : Existe al menos una i tal que $\rho_i \neq 0$

```
> prueba2<- Box.test(residuos011, lag = 20, type = "Ljung-Box")
> prueba2 #no hay evidencia en contra de que los residuales sean ruido blanco
```


Box-Ljung test

```
data: residuos011
X-squared = 17.036, df = 20, p-value = 0.6506
```

Dado que el p – $valor = 0.6506 > \alpha = 0.05$ no se rechaza H_0 .

$\therefore$ Por lo que no hay evidencia de autocorrelación en los residuos, confirmando que se comportan como ruido blanco.

Figura 7



Como se aprecia en el gráfico Q-Q plot de la figura 7, los residuales se distribuyen mayoritariamente a lo largo de la diagonal, lo que sugiere un comportamiento normal. Sin embargo, se observan ligeras desviaciones en las colas de la distribución que podrían indicar la presencia de curtosis o valores atípicos. Debido a esta ambigüedad visual, es indispensable validar el supuesto de normalidad mediante una prueba de hipótesis formal.

Se aplica la prueba de Kolmogorov–Smirnov en el modelo **ARIMA(0,1,0)** para verificar la normalidad de los residuos:

H_0 : Los residuos siguen una distribución normal

H_1 : Los residuos NO siguen una distribución normal


Exact one-sample Kolmogorov-Smirnov test

```
data: (residuos010 - mean(residuos010))/sqrt(var(residuos010))  
D = 0.12102, p-value = 0.4113  
alternative hypothesis: two-sided
```

Dado que el $p - \text{valor} = 0.4113 > \alpha = 0.05$, no se rechaza H_0

$\therefore$ Por lo que no hay evidencia en contra de la normalidad de los residuos.

Figura 8



Análogamente como en el gráfico Q-Q plot de la figura 8, los residuales se distribuyen mayoritariamente a lo largo de la diagonal, lo que sugiere un comportamiento normal. Sin embargo, se observan ligeras desviaciones en las colas de la distribución que podrían indicar la presencia de curtosis o valores atípicos. Debido a esta ambigüedad visual, es indispensable validar el supuesto de normalidad mediante una prueba de hipótesis formal.

Se aplica la prueba de Kolmogorov–Smirnov en el modelo **ARIMA(0,1,1)** para verificar la normalidad de los residuos:

H_0 : Los residuos siguen una distribución normal

H_1 : Los residuos NO siguen una distribución normal

Exact one-sample Kolmogorov-Smirnov test

```
data: (residuos011 - mean(residuos011))/sqrt(var(residuos011))
D = 0.1103, p-value = 0.5282
alternative hypothesis: two-sided
```

Dado que el $p - \text{valor} = 0.5282 > \alpha = 0.05$, no se rechaza H_0

$\therefore$ Por lo que no hay evidencia en contra de la normalidad de los residuos.

En general vemos que los modelos candidatos en los que se validaron los supuestos son ARIMA(0,1,0) y ARIMA(0,1,1)

Recordemos que:

- ARIMA(0,1,0): RMSE = 0.3483741
- ARIMA(0,1,1): RMSE = 0.3260726

Dado que el modelo ARIMA(0,1,1) presenta un menor RMSE, así como menores valores en MAE, BIC y AIC se concluye que proporciona un mejor ajuste a los datos, ya que reduce el error de predicción respecto a los otros modelos.

```
> summary(modeloarima0)
Series: inpc.ts
ARIMA(0,1,0) with drift
Box Cox transformation: lambda= 3.85

Coefficients:
      drift
    611897.45
s.e.    57620.96

sigma^2 = 1.694e+11: log likelihood = -716.83
AIC=1437.67  AICc=1437.92  BIC=1441.49

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -0.002880745 0.3483741 0.2551628 -0.00296395 0.192833 0.04259539 0.2502964
> summary(modeloarima1)
Series: inpc.ts
ARIMA(0,1,1) with drift
Box Cox transformation: lambda= 3.85

Coefficients:
      ma1      drift
    0.4261 621215.04
s.e. 0.1444 77174.79

sigma^2 = 1.541e+11: log likelihood = -714.04
AIC=1434.09  AICc=1434.61  BIC=1439.83

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -0.003186332 0.3260726 0.2376047 -0.003228361 0.1792427 0.03966435 -0.02457911
```

Por lo tanto, se concluye que el modelo ARIMA(0,1,1) proporciona el mejor ajuste, al presentar menores valores en los criterios de información y error de predicción

$$\therefore Y_t^{(3.85)} - Y_{t-1}^{(3.85)} = 621,215.04 + \varepsilon_t + 0.4261\varepsilon_{t-1}$$


Pronósticos del Índice Nacional de Precios al Consumidor (INPC)

Una vez validado que el modelo ARIMA(0,1,1) cumple con todos los supuestos estadísticos y presenta los mejores criterios de información (AIC, BIC, RMSE), se procedió a calcular las predicciones del INPC para sus próximas tres publicaciones oficiales correspondientes a los meses de mayo, junio y julio de 2026.

Para proyectar datos futuros, el modelo utiliza la esperanza condicional, definiendo el pronóstico matemáticamente óptimo como aquel que minimiza el error cuadrático medio con base en la información histórica observada hasta marzo de 2026. Al integrar un componente de promedios móviles $q=1$, el sistema incorpora la inercia inflacionaria, ajustando la predicción del mes siguiente según el "choque" o error del periodo inmediato anterior para no adivinar al azar. En sencillas palabras, como nadie sabe con total certeza qué va a pasar, el pronóstico se entrega con un "margen de error" que se va haciendo más grande conforme intentamos ver más lejos en el futuro, reconociendo que es más fácil predecir qué pasará mañana que lo que pasará en un año.

Resultados de la Proyección

FIGURA 9




A continuación, se presentan las predicciones puntuales del INPC desde la FIGURA 9, acompañadas de sus intervalos de confianza al 95%:

- **Publicación de Mayo 2026:** Se proyecta un INPC de **\$146.2696**, con un escenario del límite inferior de \$145.7821 y un escenario del límite superior de \$147.5768
- **Publicación de Junio 2026:** El modelo estima un nivel de **\$147.1015**, acotado entre \$146.3438 y \$148.2393
- **Publicación de Julio 2026:** Se anticipa que el índice se sitúe en **\$147.5125**, dentro de un rango de \$146.1445 a \$148.8462

Como dicta la teoría de series de tiempo, a medida que intentamos predecir más lejos en el futuro (de mayo hacia julio), la varianza del error aumenta. Esto se refleja visualmente en nuestros intervalos de confianza que en la FIGURA 9 se refleja en la franja azul, los cuales se van ensanchando para absorber la creciente incertidumbre del mercado. Sin embargo, la tendencia general sugiere que la inflación continuará al alza de forma moderada aumentando únicamente un 1.4% sobre el valor del INPC desde marzo a julio

Representación Gráfica (Figura 10)



Para facilitar la visualización del ajuste, se presenta una única gráfica (ver Figura 10) que contrasta la serie observada históricamente del INPC contra la serie estimada por nuestro modelo $ARIMA(0,1,1)$, culminando con la curva de los pronósticos para los tres meses solicitados y sus respectivas bandas de confianza. Se puede apreciar cómo los valores ajustados logran capturar la estructura subyacente de la inflación real.